

THÔNG TIN CHUNG CỦA NHÓM

- Link YouTube video của báo cáo (tối đa 5 phút):
<https://www.youtube.com/watch?v=hkw2GbQINtY>
- Link slides (dạng .pdf đặt trên Github của nhóm):
<https://github.com/cdevit/CS2205.CH203/blob/main/Chi%E1%BA%BFn%20Ngu%E1%BB%85n%20Minh%20-%20CS2205.JAN2026.DeCuong.FinalReport.Template.Slide.pdf>
- *Mỗi thành viên của nhóm điền thông tin vào một dòng theo mẫu bên dưới*
- *Sau đó điền vào Đề cương nghiên cứu (tối đa 5 trang), rồi chọn Turn in*
- *Lớp Cao học, mỗi nhóm một thành viên*

- Họ và Tên: Nguyễn Minh Chiến
- MSSV: 250101080



- Lớp: CS2205.CH203
- Tự đánh giá (điểm tổng kết môn): 9/10
- Số buổi vắng: 0
- Số câu hỏi QT cá nhân: 3
- Link Github:
<https://github.com/cdevit/CS2205.CH203>
- Link Youtube video của báo cáo :
<https://www.youtube.com/watch?v=hkw2GbQINtY>

ĐỀ CƯƠNG NGHIÊN CỨU

TÊN ĐỀ TÀI (IN HOA)

NGHIÊN CỨU PHƯƠNG PHÁP CĂN CHỈNH CỤM TỪ - VÙNG ẢNH CÓ NHẬN THỨC TRUY VẤN CHO BÀI TOÁN TÌM KIẾM NGƯỜI BẰNG MÔ TẢ VĂN BẢN

TÊN ĐỀ TÀI TIẾNG ANH (IN HOA)

QUERY-AWARE PHRASE-TO-REGION ALIGNMENT FOR TEXT-BASED PERSON SEARCH

I.TÓM TẮT

Text-Based Person Search[8] là bài toán tìm kiếm ảnh người dựa trên mô tả bằng ngôn ngữ tự nhiên. Với một câu mô tả như “người đàn ông mặc áo xanh, quần đen và mang balo đen”, hệ thống cần truy vấn đúng ảnh người phù hợp trong một tập ảnh lớn. Bài toán này có nhiều ứng dụng trong giám sát thông minh, phân tích video an ninh và tìm kiếm người trong môi trường công cộng. Tuy nhiên, đây là bài toán khó vì mô hình cần so khớp thông tin giữa hai dạng dữ liệu khác nhau là hình ảnh và văn bản.


Các phương pháp gần đây thường sử dụng các mô hình thị giác-ngôn ngữ như CLIP[9] để học biểu diễn chung giữa ảnh và văn bản. Cách tiếp cận này giúp cải thiện khả năng truy vấn ở mức tổng quát, nhưng vẫn còn hạn chế khi cần phân biệt các chi tiết nhỏ như màu áo, kiểu quần, giày, balo hoặc phụ kiện. Trong nhiều trường hợp, hai người có ngoại hình tương tự nhau có thể bị nhầm lẫn nếu mô hình chỉ dựa vào đặc trưng toàn cục của ảnh và câu mô tả.

Đề tài này hướng đến nghiên cứu phương pháp căn chỉnh chi tiết giữa cụm từ trong văn bản và vùng ảnh tương ứng. Cụ thể, đề tài đề xuất **cơ chế chọn token có nhận thức truy vấn (query-aware token selection)** nhằm lựa chọn các vùng ảnh không

chỉ nổi bật trong ảnh mà còn liên quan trực tiếp đến nội dung mô tả. Bên cạnh đó, đề tài nghiên cứu cơ chế học (**phrase-to-region alignment**) căn chỉnh giữa các cụm từ như “áo xanh”, “quần đen”, “balo đen” với các vùng ảnh tương ứng thông qua **Optimal Transport**[10]. Kết quả mong đợi của đề tài là xây dựng được một framework cho bài toán Text-Based Person Search, cải thiện hiệu quả truy vấn trên các bộ dữ liệu chuẩn như **CUHK-PEDES**[8], **ICFG-PEDES**[3] và **RSTPReid**[6]. Các chỉ số định lượng như Rank-1, Rank-5, Rank-10 và mAP, đề tài cũng kỳ vọng cung cấp khả năng giải thích tốt hơn thông qua việc trực quan hóa các vùng ảnh được mô hình lựa chọn theo từng truy vấn văn bản.

II.GIỚI THIỆU

Trong bối cảnh dữ liệu hình ảnh và văn bản ngày càng phổ biến, các bài toán truy vấn đa phương thức đang nhận được nhiều sự quan tâm trong lĩnh vực trí tuệ nhân tạo. Một trong những bài toán tiêu biểu là Text-Based Person Search[8], tức tìm kiếm ảnh người dựa trên mô tả bằng ngôn ngữ tự nhiên. Khác với person re-identification truyền thống, trong đó ảnh truy vấn được sử dụng để tìm lại cùng một người trong các camera khác nhau, Text-Based Person Search[8] chỉ sử dụng câu mô tả văn bản làm truy vấn. Điều này giúp bài toán linh hoạt hơn trong thực tế, vì người dùng có thể tìm kiếm một người dựa trên mô tả quan sát được mà không cần có ảnh mẫu.




Đầu vào của bài toán là một câu mô tả người và một tập ảnh người đã được crop sẵn. Đầu ra là danh sách ảnh được sắp xếp theo mức độ phù hợp với câu mô tả. Ví dụ, với truy vấn “một người phụ nữ mặc áo đỏ, quần đen và đi giày trắng”, hệ thống cần xếp các ảnh có đặc điểm tương ứng lên vị trí cao trong danh sách kết quả. Về bản chất, đây là bài toán so khớp giữa hai modality khác nhau: văn bản và hình ảnh. Văn bản biểu diễn thông tin ở dạng từ ngữ, trong khi hình ảnh biểu diễn thông tin qua màu sắc, hình dạng, vị trí và vùng không gian. Vì vậy, mô hình cần học được cách liên kết ý nghĩa giữa câu mô tả và các đặc điểm thị giác trong ảnh.

Các phương pháp hiện nay thường sử dụng các mô hình thị giác-ngôn ngữ như CLIP[9] để đưa ảnh và văn bản vào cùng một không gian biểu diễn. Khi đó, mô hình có thể tính độ tương đồng giữa embedding của ảnh và embedding của câu mô tả để thực hiện truy vấn. Tuy nhiên, cách căn chỉnh toàn cục này vẫn còn hạn chế trong những trường hợp cần phân biệt chi tiết. Ví dụ, nhiều người có thể cùng mặc áo tối màu, cùng đeo balo hoặc cùng đi giày trắng. Nếu mô hình không chú ý đúng đến các vùng ảnh liên quan với từng cụm từ trong mô tả, kết quả truy vấn có thể bị sai.

Một số nghiên cứu đã khai thác hướng căn chỉnh cục bộ giữa ảnh và văn bản bằng cách sử dụng attention, human parsing, pose estimation hoặc detector để xác định các


vùng cơ thể và thuộc tính tương ứng. Các phương pháp dựa vào mô hình phụ trợ hoặc annotation bên ngoài thường làm tăng chi phí triển khai và có thể kém linh hoạt khi áp dụng sang dữ liệu mới. Từ thực tế trên, đề tài này tập trung vào vấn đề căn chỉnh giữa cụm từ trong văn bản và vùng ảnh trong bài toán Text-Based Person Search[8]. Thay vì chỉ học sự tương đồng giữa toàn bộ ảnh và toàn bộ câu mô tả, đề tài hướng đến việc giúp mô hình học được các quan hệ chi tiết hơn, chẳng hạn “áo xanh” tương ứng với vùng áo, “quần đen” tương ứng với vùng quần, và “balo đen” tương ứng với vùng balo. Việc học các quan hệ này được kỳ vọng giúp mô hình phân biệt tốt hơn những người có ngoại hình tương tự nhau và cải thiện hiệu quả truy vấn.



Vấn đề nghiên cứu chính của đề tài có thể được phát biểu như sau: Cho một câu mô tả bằng ngôn ngữ tự nhiên và một tập ảnh người, làm thế nào để xếp hạng các ảnh theo mức độ phù hợp với câu mô tả, đồng thời học được quan hệ giữa các cụm từ mô tả và các vùng ảnh tương ứng mà không cần sử dụng nhãn căn chỉnh vùng ảnh thủ công? Để giải quyết vấn đề này, đề tài dự kiến xây dựng một framework dựa trên CLIP[9], kết hợp cơ chế chọn token có nhận thức truy vấn (**query-aware token selection**) và cơ chế (**phrase-to-region alignment**) học căn chỉnh cụm từ - vùng ảnh bằng **Optimal Transport**[10].

III. MỤC TIÊU

Xây dựng một framework cho bài toán Text-Based Person Search[8] dựa trên CLIP[9], trong đó ảnh và văn bản được biểu diễn trong cùng một không gian đặc trưng để phục vụ truy vấn ảnh người theo mô tả văn bản. Framework này cần có khả năng huấn luyện và đánh giá trên các benchmark phổ biến như CUHK-PEDES[8], ICFG-PEDES[3] và RSTPReid[6].



Nghiên cứu cơ chế chọn token có nhận thức truy vấn, giúp mô hình lựa chọn các vùng ảnh và token văn bản quan trọng dựa trên cả self-attention và độ liên quan liên phương thức. Mục tiêu này nhằm khắc phục hạn chế của các phương pháp chỉ chọn vùng ảnh nổi bật nhưng chưa chắc liên quan trực tiếp đến nội dung mô tả.

Căn chỉnh giữa cụm từ và vùng ảnh bằng Optimal Transport[10], nhằm học soft alignment giữa các phrase trong văn bản và các image patches tương ứng mà không sử dụng nhãn vùng ảnh thủ công, human parsing, pose estimation hoặc detector bên ngoài.

IV.NỘI DUNG VÀ PHƯƠNG PHÁP

1: Khảo sát bài toán và các phương pháp liên quan

Phương pháp thực hiện:

Tìm hiểu tổng quan bài toán Text-Based Person Search[8], trong đó đầu vào là mô tả văn bản và đầu ra là danh sách ảnh người được sắp xếp theo mức độ phù hợp. Nội dung này tập trung làm rõ đặc điểm của bài toán, sự khác biệt so với person re-identification[2][3][4] truyền thống và các khó khăn chính như khoảng cách ngữ nghĩa giữa ảnh và văn bản, sự tương đồng ngoại hình giữa nhiều người và nhu cầu căn chỉnh chi tiết giữa mô tả với vùng ảnh và tìm hiểu các bộ dữ liệu phổ biến như CUHK-PEDES[8], ICFG-PEDES[3] và RSTPReid[6].

Kết quả dự kiến:

Xây dựng bảng tổng hợp các nhóm phương pháp chính và bảng so sánh các công trình liên quan. Từ đó xác định khoảng trống nghiên cứu của đề tài là token selection hiện tại chưa đủ query-aware và local alignment chưa học rõ quan hệ giữa cụm từ trong văn bản với vùng ảnh tương ứng.

2: Xây dựng baseline

Phương pháp thực hiện:

Xây dựng baseline dựa trên CLIP ViT-B/16 hoặc CLIP ViT-B/32. Image encoder được dùng để trích xuất đặc trưng ảnh, còn text encoder được dùng để trích xuất đặc trưng văn bản. Baseline thực hiện truy vấn bằng cách tính độ tương đồng giữa global image embedding và global text embedding.

Mô hình được huấn luyện hoặc fine-tune trên tập dữ liệu đã chuẩn bị, sau đó đánh giá bằng các chỉ số Rank-1, Rank-5, Rank-10 và mAP.

Kết quả dự kiến:

Có code baseline, bảng cấu hình huấn luyện và bảng kết quả baseline làm mốc so sánh cho các cải tiến tiếp theo.

3: Phát triển phương pháp chọn token và căn chỉnh cụm từ - vùng ảnh

Phương pháp thực hiện:

Triển khai module Cross-Modal Guided Token Selection để chọn các image patches và text tokens quan trọng dựa trên self-attention và độ liên quan liên phương thức. Module này giúp mô hình ưu tiên các vùng ảnh và từ khóa liên quan trực tiếp đến truy vấn như áo, quần, giày, balo hoặc phụ kiện.

Với các token và patch đã chọn, đề tài trích xuất các cụm từ quan trọng trong mô tả văn bản, chẳng hạn “blue jacket”, “black pants” hoặc “white shoes”. Mỗi phrase được biểu diễn bằng embedding tổng hợp từ các token thành phần. Ở phía ảnh, các image patches được chọn đóng vai trò là các vùng ảnh ứng viên.

Đề tài xây dựng ma trận chi phí giữa phrase embeddings và patch embeddings dựa trên cosine distance. Optimal Transport[10] được sử dụng để học quan hệ mềm nhiều-nhiều giữa cụm từ và vùng ảnh, giúp mô hình căn chỉnh tốt hơn các chi tiết mô tả trong văn bản với các vùng tương ứng trên ảnh.

Kết quả dự kiến:

Module chọn token có nhận thức truy vấn, module căn chỉnh cụm từ - vùng ảnh, ma trận chi phí và kết quả căn chỉnh bằng Optimal Transport[10].

V.KẾT QUẢ MONG ĐỢI

Đề tài hướng đến các kết quả chính: xây dựng một framework hoàn chỉnh cho bài toán Text-Based Person Search dựa trên CLIP[9], có khả năng nhận đầu vào là câu

mô tả văn bản và truy vấn danh sách ảnh người phù hợp từ cơ sở dữ liệu, đề xuất cơ chế chọn token có nhận thức truy vấn, giúp mô hình tập trung vào các vùng ảnh liên quan trực tiếp đến nội dung mô tả, từ đó cải thiện căn chỉnh cục bộ giữa hai modality, triển khai học căn chỉnh cụm từ – vùng ảnh bằng Optimal Transport[10], cho phép mô hình học quan hệ mềm giữa các phrase và image patch tương ứng mà không cần nhãn thủ công, cải thiện hiệu quả truy vấn so với baseline qua các chỉ số Rank-1, Rank-5, Rank-10 và mAP, hoặc trong trường hợp kết quả định lượng chưa vượt trội, làm rõ vai trò từng thành phần qua ablation study và phân tích nguyên nhân, và cuối cùng cung cấp các phân tích định tính như selected patches, attention map và phrase-region transport map nhằm tăng khả năng giải thích của phương pháp đề xuất.

VI. TÀI LIỆU THAM KHẢO

- [1]. Hao Yin, Xin Man, Feiyu Chen, Jie Shao, Heng Tao Shen:
Cross-Modal Full-Mode Fine-Grained Alignment for Text-to-Image Person Retrieval.
ACM Trans. Multim. Comput. Commun. Appl. 22(5): 135:1-135:20 (2026).
- [2]. Shuanglin Yan, Jun Liu, Neng Dong, Liyan Zhang, Jinhui Tang:
Cross-modal Collaborative Representation Learning for Text-to-Image Person
Retrieval. IJCAI 2025: 2152-2160.
- [3]. Zefeng Ding, Changxing Ding, Zhiyin Shao, Dacheng Tao:
Semantically Self-Aligned Network for Text-to-Image Part-aware Person
Re-identification. [arXiv/2107.12666](https://arxiv.org/abs/2107.12666) (2021).
- [4]. Zhiyin Shao, Xinyu Zhang, Meng Fang, Zhifeng Lin, Jian Wang, Changxing
Ding:
Learning Granularity-Unified Representations for Text-to-Image Person
Re-identification. ACM Multimedia 2022: 5566-5574.
- [5]. Xiujun Shu, Wei Wen, Haoqian Wu, Keyu Chen, Yiran Song, Ruizhi Qiao, Bo

Ren, Xiao Wang: See Finer, See More: Implicit Modality Alignment for Text-based Person Retrieval. ECCV Workshops 2022: 624-641.

[6]. Aichun Zhu, Zijie Wang, Yifeng Li, Xili Wan, Jing Jin, Tian Wang, Fangqiang Hu, Gang Hua: DSSL: Deep Surroundings-person Separation Learning for Text-based Person Retrieval. ACM Multimedia 2021: 209-217.

[7]. Tien-Huy Nguyen, Huu-Loc Tran, Thanh Duc Ngo: ITSELF: Attention Guided Fine-Grained Alignment for Vision-Language Retrieval. WACV 2026: 1448-1458.

[8]. Shuang Li, Tong Xiao, Hongsheng Li, Bolei Zhou, Dayu Yue, Xiaogang Wang: Person Search with Natural Language Description. CVPR 2017: 1970-1979.

[9]. Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, Ilya Sutskever: Learning Transferable Visual Models From Natural Language Supervision. ICML 2021: 8748-8763.

[10] Marco Cuturi. Sinkhorn Distances: Lightspeed Computation of Optimal Transport. Advances in Neural Information Processing Systems 26, pp. 2292–2300, 2013.