

QUERY-AWARE PHRASE-TO-REGION ALIGNMENT FOR TEXT-BASED PERSON SEARCH

Nghiên cứu phương pháp căn chỉnh cụm từ - vùng ảnh có nhận thức truy vấn cho bài toán tìm kiếm người bằng mô tả văn bản

Nguyễn Minh Chiến – 250101080

University of Information Technology, Vietnam National University - Ho Chi Minh City
CS2205.JAN2026

What?




- Text-Based Person Search** là bài toán tìm kiếm ảnh người bằng mô tả ngôn ngữ tự nhiên.
- Đầu vào gồm một câu truy vấn văn bản và tập ảnh người ứng viên.
- Đầu ra là danh sách ảnh được xếp hạng theo mức độ phù hợp với mô tả.

Why?



- Bài toán có ý nghĩa thực tiễn cao trong giám sát thông minh, tìm kiếm người và phân tích video an ninh.
- Text-Based Person Search là hướng nghiên cứu tiêu biểu, kết nối giữa thị giác máy tính, xử lý ngôn ngữ và truy hồi đa phương thức.
- Các phương pháp hiện tại vẫn còn khoảng trống ở việc căn chỉnh chi tiết giữa mô tả văn bản và vùng ảnh, nên đề tài này có giá trị nghiên cứu và tiềm năng cải tiến.

Overview



Description

1

1. Problem Statement



Inputs:

- Truy vấn văn bản
- Tập ảnh người ứng viên



Output:

- Danh sách ảnh được xếp hạng theo độ phù hợp



Challenge:

- Không căn chỉnh nghĩa ảnh - văn bản
- Nhiều người có ngoại hình tương tự
- Cần liên kết chi tiết mô tả với vùng ảnh



2. Proposed Method

A. CLIP Baseline

- Dùng image encoder và text encoder để trích xuất đặc trưng
- Tính độ tương đồng giữa global image embedding và global text embedding



B. Query-Aware Token Selection

- Chọn image patches và text tokens quan trọng
- Kết hợp ngữ cảnh truy vấn để liên quan đến phương thức



C. Phrase-to-Region Alignment

- Tính ma trận chú ý hai chiều "blue jacket", "black pants" với "vùng ảnh"
- Xây dựng cost matrix tối ưu quán sử dụng Optimal Transport-hungarian để học sự tương thích chi tiết-cụm giữa phrase và image patches.



3

3. Evaluation



Datasets:

- CUHK-PEDES
- ICFG-PEDES
- RSTReid



Metrics:

- Rank-1, Rank-5, Rank-10
- mAP



Additional goal:

- Trực quan hóa vùng ảnh được chọn theo từng truy vấn để tăng khả năng giải thích.

Expected Results



Framework

Xây dựng framework căn chỉnh cụm từ - vùng ảnh có tri thức truy vấn trên CLIP.



Hiệu quả

Cải thiện độ chính xác truy hồi đáng kể so với mô hình cơ sở.



Local Alignment

Mô hình học được nhiều-nhiều alignment chi tiết giữa mô tả và vùng ảnh.



Performance

Vượt trội so với hiện hữu quả trên các bộ dữ liệu chuẩn trong Text-Based Person Search.