

QUERY-AWARE PHRASE-TO-REGION ALIGNMENT FOR TEXT-BASED PERSON SEARCH

NGUYỄN MINH CHIẾN - 250101080

Lớp: CS2205.CH203

GVHD: PGS.TS. Lê Đình Duy

Tóm tắt

- Lớp: CS2205.JAN2026
- Link Github của nhóm: <https://github.com/cdevit/CS2205.CH203>
- Link YouTube video:
<https://www.youtube.com/watch?v=hkw2GbQINtY>



Nguyễn Minh Chiến

Giới thiệu

MÔ TẢ BÀI TOÁN

Đầu vào / Input

Truy vấn bằng ngôn ngữ tự nhiên

a woman wearing a red shirt,
black pants and white shoes

Tập ảnh ứng viên (Gallery)



Tính độ tương
đồng $S(T_q, I_j)$
So khớp (Ranking)



Đầu ra / Output

Rank-1 Rank-2 Rank-3 Rank-4 Rank-5



Phù hợp nhất

Ít phù hợp hơn


Tính ứng dụng cao: Cho phép tìm kiếm linh hoạt trong giám sát thông minh và môi trường công cộng chỉ qua quan sát bằng lời, hoàn toàn không cần ảnh mẫu ban đầu.

Giới thiệu

	Person Re-identification (Truyền thống)	Text-Based Person Search (Nghiên cứu này)
Đầu vào (Input)	Ảnh người -> Ảnh người (Image-to-Image) 	Câu mô tả -> Ảnh người (Text-to-Image) 
Thách thức cốt lõi (Core Challenge)	Khác biệt góc máy, ánh sáng, tư thế.	Khoảng cách ngữ nghĩa (Semantic gap) giữa hai dạng dữ liệu hoàn toàn khác biệt.
Tính linh hoạt (Flexibility)	Thấp – Bắt buộc phải có ít nhất một ảnh mẫu để làm truy vấn.	Cao – Người dùng chỉ cần nhập văn bản mô tả những gì họ quan sát được.

Giới thiệu

Cách tiếp cận hiện tại (Global Alignment)



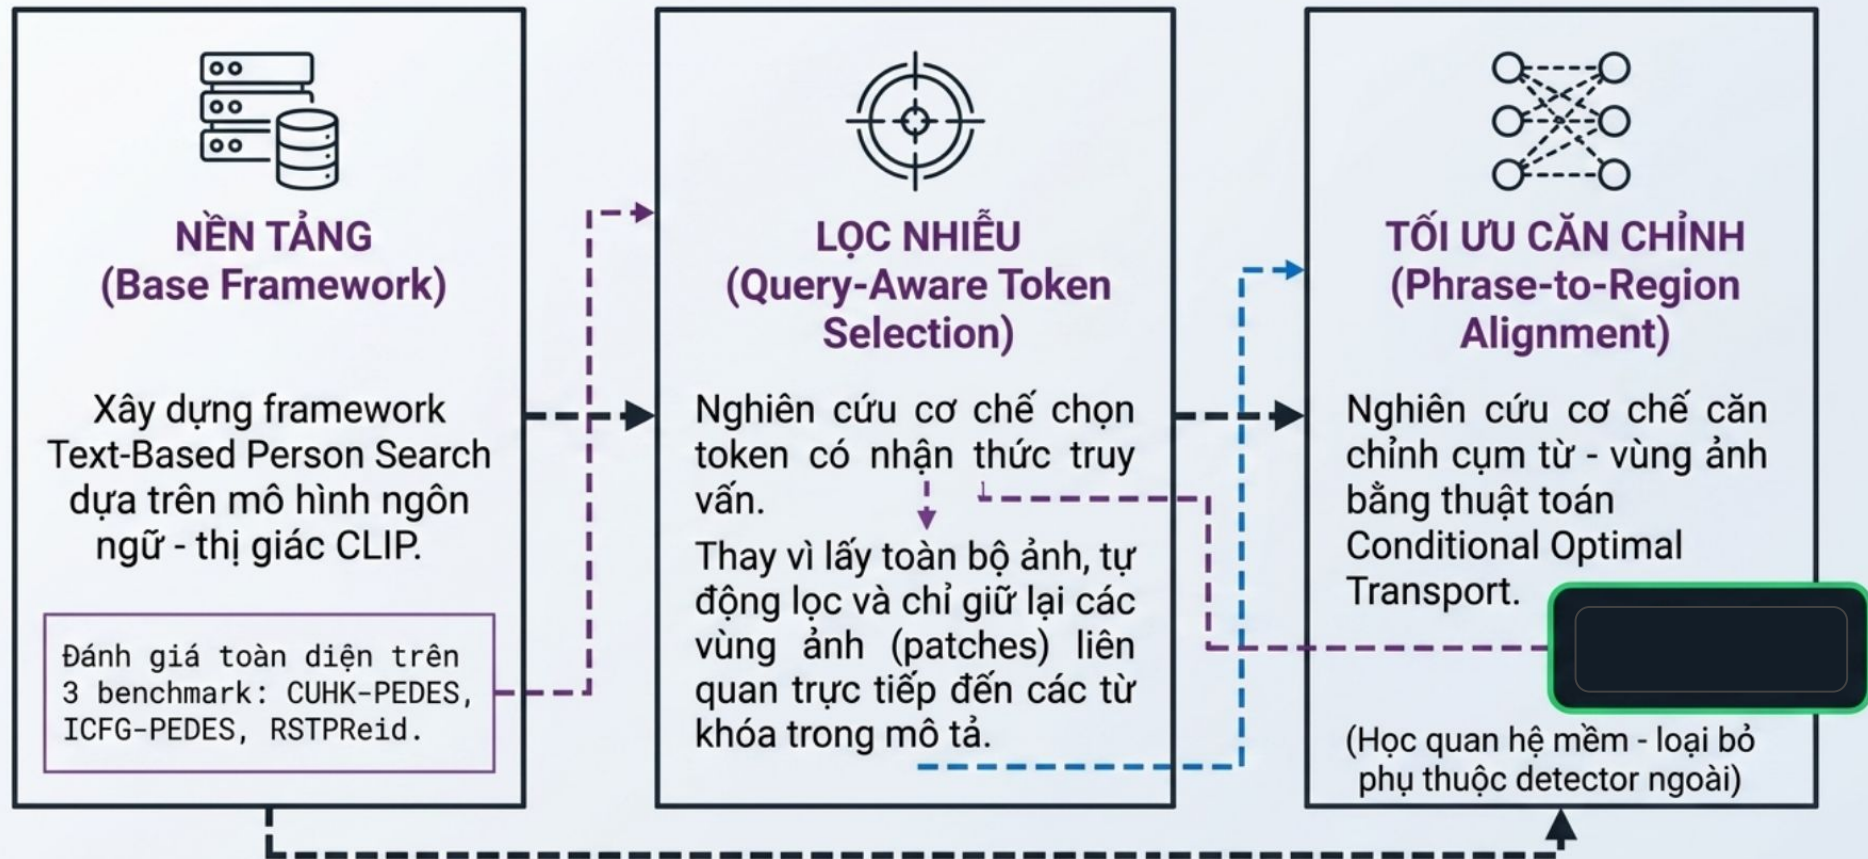
Mô hình như CLIP gom toàn bộ câu và toàn bộ ảnh vào một không gian biểu diễn chung.

Điểm mù chi tiết (The Blind Spot)



Khi nhiều người có ngoại hình tương tự, sự khác biệt nằm ở chi tiết nhỏ. Căn chỉnh toàn cục bỏ qua các vùng ảnh chi tiết này, dẫn đến xếp hạng **sai kết quả**

Mục tiêu



Nội dung và Phương pháp

PHƯƠNG PHÁP ĐỀ XUẤT

Chuyển dịch từ so khớp toàn cục sang học quan hệ chi tiết cục bộ (Local Alignment) mà không cần nhãn giám sát thủ công.

1. Query-Aware Token Selection


Chọn lọc vùng ảnh và từ khóa có chủ đích.



Không chỉ chọn vùng ảnh nổi bật một cách mù quáng, hệ thống đánh giá dựa trên sự liên quan đa phương thức để giữ lại các token thực sự chứa thông tin truy vấn.

2. Phrase-to-Region Alignment


Học sự tương ứng chính xác.



Sử dụng Conditional Optimal Transport để học quan hệ mềm (nhiều-nhiều) giữa cụm từ và vùng ảnh. Hệ thống tự động hiểu 'áo xanh' nằm ở đâu trên ảnh mà không cần bounding box.

Nội dung và Phương pháp

PHRASE TO REGION ALIGNMENT



Học không giám sát vùng Mô hình tự khám phá mối quan hệ qua tín hiệu từ các cặp image-text, loại bỏ hoàn toàn chi phí gán nhãn thủ công (human parsing / pose estimation).

Nội dung và Phương pháp

Bước 1: Khảo sát & Xây dựng Baseline

01



- Nghiên cứu bộ dữ liệu: CUHK-PEDES, ICFG-PEDES, RSTPReid.
- Xây dựng baseline sử dụng mô hình CLIP ViT-B/16 hoặc B/32.
- Đo lường các chỉ số cơ sở bằng biểu diễn toàn cục (Global embedding).

Bước 2: Phát triển Token Selection


02



- Tích hợp module Cross-Modal Guided Token Selection.
- Sử dụng self-attention để chọn các vùng ảnh ưu tiên chứa từ khóa như áo, quần, balo, giày.

Bước 3: Tối ưu Optimal Transport

03



- Xây dựng ma trận chi phí (Cost matrix) dựa trên khoảng cách Cosine.
- Áp dụng Conditional Optimal Transport để học quan hệ “mềm” nhiều-nhiều.

Kết quả dự kiến

Đánh giá hiệu năng và Kết quả kỳ vọng

Dữ liệu Đánh giá (Benchmarks)

Kiểm chứng tính mạnh mẽ trên 3 bộ dữ liệu chuẩn:

CUHK-PEDES

ICFG-PEDES

RSTPReid

Chỉ số Định lượng (Quantitative)

Mục tiêu: Cải thiện hiệu suất so với baseline trên các thước đo khắt khe nhất:

Rank-1 Rank-5 Rank-10 mAP

- Cung cấp Ablation study để chứng minh vai trò độc lập của từng module.

Tính minh bạch & Giải thích (Explainability)

Việc chứng minh được “vì sao” AI chọn ảnh đó giúp tăng độ tin cậy và khả năng giải thích của hệ thống.



- Trực quan hóa **Selected patches**
- Trực quan hóa **Attention maps**
- Phân tích **Phrase-region transport maps**

Tài liệu tham khảo

- [1]. Hao Yin, Xin Man, Feiyu Chen, Jie Shao, Heng Tao Shen: Cross-Modal Full-Mode Fine-Grained Alignment for Text-to-Image Person Retrieval. ACM Trans. Multim. Comput. Commun. Appl. 22(5): 135:1-135:20 (2026).
- [2]. Shuanglin Yan, Jun Liu, Neng Dong, Liyan Zhang, Jinhui Tang: Cross-modal Collaborative Representation Learning for Text-to-Image Person Retrieval. IJCAI 2025: 2152-2160.
- [3]. Zefeng Ding, Changxing Ding, Zhiyin Shao, Dacheng Tao: Semantically Self-Aligned Network for Text-to-Image Part-aware Person Re-identification. [arXiv/2107.12666](https://arxiv.org/abs/2107.12666) (2021).
- [4]. Zhiyin Shao, Xinyu Zhang, Meng Fang, Zhifeng Lin, Jian Wang, Changxing Ding: Learning Granularity-Unified Representations for Text-to-Image Person Re-identification. ACM Multimedia 2022: 5566-5574.
- [5]. Xiujun Shu, Wei Wen, Haoqian Wu, Keyu Chen, Yiran Song, Ruizhi Qiao, Bo Ren, Xiao Wang: See Finer, See More: Implicit Modality Alignment for Text-based Person Retrieval. ECCV Workshops 2022: 624-641.
- [6]. Aichun Zhu, Zijie Wang, Yifeng Li, Xili Wan, Jing Jin, Tian Wang, Fangqiang Hu, Gang Hua: DSSL: Deep Surroundings-person Separation Learning for Text-based Person Retrieval. ACM Multimedia 2021: 209-217.
- [7]. Tien-Huy Nguyen, Huu-Loc Tran, Thanh Duc Ngo: ITSELF: Attention Guided Fine-Grained Alignment for Vision-Language Retrieval. WACV 2026: 1448-1458.
- [8]. Shuang Li, Tong Xiao, Hongsheng Li, Bolei Zhou, Dayu Yue, Xiaogang Wang: Person Search with Natural Language Description. CVPR 2017: 1970-1979.
- [9]. Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, Ilya Sutskever: Learning Transferable Visual Models From Natural Language Supervision. ICML 2021: 8748-8763.